

Modelagem com Indicadores Técnicos de Mercado: Otimização por Algoritmo Genético para Previsão dos Movimentos do Mini-índice Ibovespa

CORREA, Othavio Christmann.

DALMAZO, Bruno L.; PINTO, Richard F.;
BORGES, Eduardo N.; LUCCA, Giancarlo;
CARDOSO, Fabian C.; BERRI, Rafael A.
othavioccorrea@furg.br

Universidade Federal do Rio Grande - FURG;
Universidade Católica de Pelotas - UCPEL; Universidade de Rio Verde - UniRV.

Palavras-chave: Aprendizagem de Máquina; Seleção de atributos; Algoritmo Genético; Bollinger Bands; Mercado Futuro.

1 INTRODUÇÃO

A B3¹, principal bolsa de valores do Brasil, desempenha um papel central no desenvolvimento do mercado financeiro nacional. No qual proporciona um ambiente produtivo e confiável para negociações de ativos.

Com um papel importante no mercado financeiro, a análise técnica ajuda investidores com ferramentas que auxiliam em identificar tendências, pontos de inflexão e potenciais oportunidades de negociação (GRIFFIOEN, 2003). Uma destas ferramentas são os indicadores técnicos, neste estudo serão utilizados as Bandas de Bollinger e as Médias Móveis Simples (MMS).

O Algoritmo Genético (AG) é inspirado no processo de seleção natural e genética, esta técnica de busca e otimização funciona por meio de operadores como seleção, cruzamento e mutação (MATHEW, 2012).

A composição desta pesquisa está da seguinte maneira: na Seção 2 será apresentada a metodologia. A Seção 3 mostrará os resultados e discussão sobre o estudo realizado; por último, na Seção 4 serão feitas as considerações finais da pesquisa.

2 METODOLOGIA

O trabalho utiliza os Mini-índices Ibovespa com o maior volume de operações de cada mês, com os dados intradiários de 5 minutos entre os períodos de 1 de janeiro a 30 de junho de 2024, com o objetivo de identificar suas tendências. Vale ressaltar que estes mini índices possuem um grande volume de negociações, pelo seu baixo custo, e isto ajuda a capturar as variações de preço nesses curtos intervalos de tempo.

Estes dados foram retirados do banco de dados BovDB.v2 (SOUZA et al., 2024), uma versão atualizada do BovDB (CARDOSO et al., 2022), possuem todas as empresas do B3 entre o período de 1995 até 2024, além dos dados intradiários a partir de janeiro de 2024 até junho do mesmo ano.

¹ <https://www.b3.com.br>

Para a geração das Bandas de Bollinger, que são formadas a partir de três faixas, uma sendo a MMS de um determinado período, e as outras duas faixas seriam as bandas inferiores e superiores, geradas a partir de um fator de desvio multiplicado pelo desvio-padrão.

Buscando ter os melhores parâmetros (período e fator de desvio) das Bandas de Bollinger, a técnica de AG foi implementada, a partir dos topos e vales. O objetivo era que apenas topos e vales ficassem acima e abaixo, respectivamente, das bandas, assim o restante dos candles permanecessem dentro das bandas. Caso algum candle estivesse de fora das bandas, o mesmo seria penalizado; já topos e vales de fora das bandas seriam os ganhos. Para isso, foi analisado o parâmetro período num intervalo de [2, 30] e o parâmetro fator de desvio no intervalo [0.2, 4]. A tabela 1 mostra os parâmetros usados no modelo do AG.

Tabela 1: Parâmetros do AG.

Parâmetro	Peso
Probabilidade acasalamento	0.8
Probabilidade mutação	0.05
Numero de gerações	1000
População inicial	20
Seleção por torneio	Sim
Cruzamento	Dois Pontos

Juntamente com as Bandas de Bollinger, o indicador técnico de MMS foi empregado com os períodos de 3,5,7,9 e 11. Neste momento, para termos maior eficácia e garantir que não haja perda de dados, será feita a normalização desses dois indicadores técnicos. Assim, seus valores ficarão em um intervalo de 0 a 1, ajudando os indicadores a não ficarem em intervalos com diferentes escalas.

A Seleção de características é um processo que retira características determinadas como irrelevantes do modelo. Existem diversos métodos para realizar este processo, nesta pesquisa foram utilizados os: CFS SubsetEval, ClassifierAttributeEval, CorrelationAttributeEval, PCA, Information Gain e ReliefF. Estes métodos dão a ordem de importância para as 6 características que existem no dataset, e para buscarmos os conjuntos de características mais interessantes, o algoritmo de Random Forest, apenas com o parâmetro de número de árvores, foi aplicado, treinando a característica de maior importância, depois a primeira com a segunda e assim por diante.

Após os conjuntos mais interessantes escolhidos, duas técnicas de Aprendizagem de Máquina serão aplicadas para, deste modo, sabermos a eficiência final do modelo. Estes serão a Multi-Layer Perceptron (MLP) e o Random Forest, que foram aplicados ao AG para encontrar os parâmetros perfeitos para cada conjunto selecionado de características; as especificações do AG são as mesmas da Tabela 1.


Com os melhores parâmetros encontrados, pode-se gerar o modelo robusto, sendo aplicada a validação cruzada estratificada de K folds, para preservar a distribuição de classes e, para a visualização dos resultados, as matrizes de confusão foram geradas.

3 RESULTADOS E DISCUSSÃO

Nesta seção será apresentado os resultados obtidos desta pesquisa. Para poder comparar futuramente, foi aplicado os algoritmos Random Forest e MLP, com validação cruzada estratificada com 9-folds com todos os atributos do dataset, dividido o período de treino entre janeiro a março de 2024, e o período de teste de abril a junho de 2024. Assim, obtendo no Random Forest uma acurácia de 56.77% na validação cruzada, e no teste 55.37%. Já no modelo MLP, obteve-se a acurácia de 56.83% na validação cruzada, e 56.00% no teste.

Para selecionar os conjuntos de atributos mais relevantes, métodos de seleção de atributos foram aplicados e a partir das listas de importância obtidas, realizou-se o processo de encontrar as acurácias de cada conjunto possível de características. A Figura 1 mostra a evolução da acurácia em cada conjunto de características.

Figura 1: Acurácia de cada conjunto de atributos.



Fonte: O(s) autor(es).

Neste momento, os conjuntos de atributos mais interessantes utilizados serão: o que obteve a maior acurácia com 5 atributos pelo método ReliefF, e os três com 3 atributos que tiveram a mesma acurácia usando ReliefF, Information Gain e ClassifierAttributeEval. A Tabela 2 mostra os conjuntos de atributos de cada método.

Tabela 2: Conjunto de atributos interessantes de cada método.

<i>Método</i>	<i>Atributos</i>
ReliefF	'BandsNorm', 'NSMA3', 'NSMA5', 'NSMA7', 'NSMA9'
ReliefF e ClassifierA.E.	'BandsNorm', 'NSMA3', 'NSMA5'
Information Gain	'NSMA5', 'NSMA7', 'BandsNorm'


Com os conjuntos selecionados, as técnicas de Aprendizagem de Máquina Random Forest e MLP serão utilizadas. Além de serem tunadas com o AG para buscar seus parâmetros ideais para cada conjunto, com base no objetivo de conseguir a maior acurácia possível nos dados de teste.

No modelo Random Forest, os métodos ReliefF e ClassifierAttributeEval obtiveram 56,79% de acurácia nos dados de teste e 67,59% nos dados de treinamento. O método Information Gain teve uma acurácia de 56,55% nos dados de teste e 62,43% nos dados de treinamento. O método ReliefF com 5 atributos teve a acurácia de 58,17% no teste e de 71,45% no treinamento.

No modelo MLP, os métodos ReliefF e ClassifierAttributeEval obtiveram 58,47% de acurácia nos dados de teste e 70,16% nos dados de treinamento. O método Information Gain teve uma acurácia de 57,42% nos dados de teste e 67,00% nos dados de treinamento. Já o método ReliefF com 5 características obteve a acurácia de 59,95% no teste e de 73,67% no treinamento.

Para visualizar, a Figura 2 mostra os resultados obtidos para cada conjunto, com as acurácias de validação cruzada e dos dados de teste.

Figura 2: Validação cruzada e testes de precisão nos modelos.



Fonte: O(s) autor(es).

4 CONSIDERAÇÕES FINAIS

Nesta pesquisa foram utilizados os indicadores técnicos normalizados de MMS de 3,5,7,9 e 11, e as Bandas de Bollinger com os parâmetros perfeitos encontrados com AG. Para gerarmos um modelo robusto, métricas de Seleção de Atributos foram implementadas para buscar os conjuntos de características interessantes. Para predição, os algoritmos de Aprendizagem de Máquina Random Forest e MLP tunados com AG foram utilizados. Pode-se notar, com os processos realizados, que houve uma crescente melhora nas acurácias do modelo, mostrando a importância destes procedimentos realizados.

5 REFERÊNCIAS

- CARDOSO, F. C. et al. Bovdb: a data set of stock prices of all companies in b3 from 1995 to 2020. **Journal of Information and Data Management**, v. 13, n. 1, 2022.
- GRIFFIOEN, G. A. Technical analysis in financial markets. 2003.
- MATHEW, T. V. Genetic algorithm. **Report submitted at IIT Bombay**, v. 53, p. 18–19, 2012.
- SOUZA, A. S. et al. Dataset for intraday analysis of b3 stock prices. **Dataset for Intraday Analysis of B3 stock prices**, Harvard Dataverse, 2024.